

**Trường Đại Học Công Nghệ Thông Tin
Đại Học Quốc Gia Thành Phố Hồ Chí Minh**

Môn học: Lập trình Python cho máy học – CS116.Q11

**BÁO CÁO TIẾN ĐỘ ĐỒ ÁN
PHÂN TÍCH DỮ LIỆU
(EDA)**

Người thực hiện:

Trương Hoàng Thành An - 23520032

Nguyễn Xuân An - 23520023

Lê Ngọc Thành - 23521443

Thành phố Hồ Chí Minh, ngày 06 tháng 10 năm 2025

MỤC LỤC

1. Mô tả dataset	3
1.1. dữ liệu file sales_pers.item_chunk	3
1.2. dữ liệu file sales_pers.users_chunk	3
1.3. dữ liệu file sales_pers.purchase_history_daily_chunk	3
2. Phân tích dữ liệu (EDA)	4
2.1. phân tích đơn biến	4
2.1.1. Dữ liệu items	4
2.1.2. Dữ liệu users	8
2.1.3. Dữ liệu purchases	11
2.2. Phân tích Đa biến	13
Biểu đồ 1: Phân tích giá trị giao dịch	13
Biểu đồ 2: Phân tích giá trị Khách hàng	13
Biểu đồ 3: Phân tích hiệu suất danh mục	14
Biểu đồ 4: Phân tích giỏ hàng	14
Biểu đồ 5: phân tích thời gian mua sắm	15
Biểu đồ 6: Mối quan hệ giữa giá và lợi nhuận	16
Biểu đồ 7: Giá trung bình theo danh mục	17
Biểu đồ 8: số lượng sản phẩm mua theo membership	18
Biểu đồ 9: Doanh thu theo thời gian	19
Biểu đồ 10: Phân bố người dùng theo vùng	20
3. Nhận định và đề xuất tiền xử lý dữ liệu	21
3.1. Tổng hợp các vấn đề từ bộ dữ liệu	21
3.1.1. Dữ liệu Sản phẩm (Items)	21
3.1.2. Dữ liệu Người dùng (Users)	21
3.1.3. Dữ liệu Giao dịch (Purchases)	21
3.2. Đề Xuất	21
Những trường thông tin nào không có nhiều thông tin → nên loại bỏ	21
Những trường thông tin nào cần xử lý giá trị thiếu (NULL)	21
Những trường thông tin nào cần xử lý ngoại lệ (Outlier)	22

1. Mô tả dataset

Bộ dữ liệu liên quan là một tập dữ liệu thương mại điện tử (E-commerce Transaction Dataset).

Bao gồm 3 loại file chính:

- 1 file sales_pers.item_chunk.
- 10 file sales_pers.users_chunk.
- 72 file sales_pers.purchase_history_daily_chunk.

1.1. dữ liệu file sales_pers.item_chunk.

file sales_pers.item_chunk nói về thông tin sản phẩm với 34 thông tin. Mỗi sản phẩm được trình bày thành 1 dòng duy nhất.

Các nhóm thông tin chính:

- **Nhận dạng:** *item_id, p_id*
- **Giá & lợi nhuận:** *price, gp, sale_status*
- **Phân loại sản phẩm:** *category_l1, category_l2, category_l3, category*
- **Thuộc tính chi tiết:** *color, size, weight, origin, material, volume, item_type*
- **Đối tượng khách hàng:** *gender_target, age_group*
- **Thông tin mô tả & hình ảnh:** *description, description_new, image_url*
- **Thông tin sản xuất:** *brand, manufacturer*
- **Thông tin thời gian:** *creation_timestamp, created_date, updated_date, last_sync_date*
- **Thông tin kỹ thuật & đồng bộ:** *sync_status_id, sync_error_message, is_deleted*

1.2. dữ liệu file sales_pers.users_chunk.

file sales_pers.users_chunk nói về thông tin khách hàng với 18 thông tin. Mỗi khách hàng tương ứng với 1 dòng.

Các nhóm thông tin chính:

- **Nhận dạng giao dịch:** *timestamp, date_key, created_date, updated_date*
- **Thông tin người mua:** *user_id, customer_id, location*
- **Thông tin sản phẩm:** *item_id*
- **Chi tiết mua hàng:** *event_type, event_value, price, quantity, discount*
- **Kênh & thanh toán:** *channel, payment*
- **Trạng thái dữ liệu:** *is_deleted*

1.3. dữ liệu file sales_pers.purchase_history_daily_chunk.

file sales_pers.purchase_history_daily_chunk nói về lịch sử giao dịch với 16 thông tin. Mỗi dòng là một giao dịch cụ thể.

Các nhóm thông tin chính:

- **Nhận dạng:** *customer_id, user_id*
- **Thông tin cá nhân:** *gender, membership*
- **Thông tin địa lý:** *location, province, district, region, location_name*

- **Hành vi sử dụng ứng dụng:** *install_app, install_date*
- **Thông tin thời gian:** *timestamp, created_date, updated_date, last_sync_date*
- **Thông tin đồng bộ & trạng thái:** *sync_status_id, sync_error_message, is_deleted*


2. Phân tích dữ liệu (EDA)

2.1. phân tích đơn biến

2.1.1. Dữ liệu items

Biểu đồ 1: Đặc trưng số


- Biểu đồ histogram thể hiện phân bố của các cột số như price và gp.
- Phần lớn sản phẩm có giá dưới khoảng 200 000 VNĐ, cho thấy tập trung nhiều ở nhóm hàng bình dân; một số sản phẩm có giá vượt trội tạo thành đuôi phải dài (right-skewed) – đây là dấu hiệu của outlier.
- Tương tự, giá trị lợi nhuận (gp) cũng phân bố lệch phải, chứng tỏ phần lớn sản phẩm có biên lợi nhuận thấp, chỉ vài nhóm hàng cao cấp mang lại lợi nhuận cao.



Biểu đồ 2: Đặc trưng phân loại chính

- **Biểu đồ trái Top 10 Danh mục cấp 1**
 - Thời trang chiếm áp đảo với hơn 14.000 sản phẩm, gần gấp đôi các nhóm còn lại.
 - Tiếp theo là Phụ kiện, Đồ chơi & Sách, Babycare.

- Các nhóm nhỏ hơn: Thực phẩm cho bé, Textile, Thực phẩm cho gia đình, Tã, Sữa, Hóa mỹ phẩm gia đình.
- Bộ dữ liệu mất cân bằng mạnh giữa các nhóm; gần như toàn bộ sản phẩm tập trung ở nhóm Thời trang.
- Điều này gợi ý: nếu dùng cho mô hình gợi ý (recommendation), ta cần cân bằng danh mục hoặc gán trọng số theo tần suất xuất hiện.
- **Biểu đồ Top 10 Danh mục cấp 2**
 - Cơ cấu hàng cũ vượt trội (~9.000 sản phẩm).
 - Sau đó là các nhóm thời trang con như Thời trang bé trai, Thời trang bé gái, Modal kháng khuẩn, 1Y+, Quần áo & Phụ kiện sơ sinh, v.v.
 - Các nhánh con thuộc nhóm “Thời trang” tiếp tục chiếm phần lớn — củng cố kết luận ở biểu đồ 1.
 - Sự hiện diện của nhãn Cơ cấu hàng cũ cho thấy dữ liệu có thể chứa sản phẩm đã ngừng bán / hàng tồn, cần lọc ra khi huấn luyện mô hình.
- **Biểu đồ phải – “Top 10 Thương hiệu” (brand)**
 - Ba thương hiệu lớn nhất:
 - Animo
 - Không xác định
 - CF (ConCung Fashion)
 - Các thương hiệu nhỏ hơn: Thương hiệu khác, Con Cung, TOYCITY, ConCung Good, Nous, Pigeon, Mesuca.
 - Animo chiếm số lượng vượt trội (>8.000 sản phẩm).
 - Tỷ lệ “Không xác định” cao → nhiều dòng dữ liệu thiếu hoặc nhập sai nhãn thương hiệu → cần làm sạch (data cleaning).
 - Các thương hiệu con của Con Cung (CF, ConCung Good) xuất hiện nhiều, có thể nhóm lại trong phân tích nâng cao.




Biểu đồ 3: Đặc trưng Thuộc tính sản phẩm

- **Biểu đồ top 10 loại sản phẩm**

- Nhãn “Không xác định” chiếm áp đảo (~10.000 sản phẩm) ⇒ dữ liệu bị thiếu hoặc chưa được gán nhãn chính xác.
- Các nhóm còn lại khá nhỏ:
 - Bộ quần áo (~4.000)
 - Áo, Bodysuit, Quần, Giày tập đi... mỗi loại chỉ vài trăm – vài nghìn mẫu.
- Nhận định: dữ liệu không cân bằng; nếu dùng cho ML cần xử lý nhãn “Không xác định” (xem xét loại bỏ hoặc gán lại).
- **Biểu đồ top 10 xuất xứ**
 - “Không xác định” cũng chiếm rất lớn (>20.000).
 - Xuất xứ rõ ràng như Việt Nam, Trung Quốc, Hàn Quốc chỉ chiếm tỷ lệ nhỏ.
 - Nhận định: Thuộc tính origin bị thiếu nghiêm trọng → cần xử lý dữ liệu NULL / missing values.
- **biểu đồ đối tượng giới tính**
 - biểu đồ gồm:
 - Không xác định: ~18.000 sản phẩm.
 - Bé Gái: ~4.000 → cao nhất trong nhóm đã xác định.
 - Bé Trai, Sơ sinh, Unisex: ít hơn nhiều.
 - Nhận định: thuộc tính này cũng mất cân bằng, dữ liệu “Không xác định” chiếm đa số và có thể ảnh hưởng đến phân tích phân khúc khách hàng.
- **Biểu đồ top 10 nhóm tuổi**
 - Không xác định: ~16.000 → áp đảo.
 - Các nhóm cụ thể (Từ 3Y, 9M–12M, ...) phân bố rất nhỏ và rời rạc.
 - Nhận định: cần chuẩn hoá & làm sạch cột age_group, đồng thời xử lý dữ liệu trống.

Phân Tích các Đặc Trưng Thuộc Tính Sản Phẩm



Biểu đồ 4: Đặc trưng trạng thái và thời gian

• Trạng thái bán

- Phần lớn sản phẩm có `sale_status = 0` (~22.000 sản phẩm) → hiện không còn bán.
- Chỉ có khoảng ~4.000 sản phẩm còn đang bán (`sale_status = 1`).
- Insight: Tỷ lệ sản phẩm còn bán chỉ chiếm khoảng 15–20% tổng số → cần tập trung phân tích hoặc lọc dữ liệu này cho các bài toán kinh doanh/ML vì phần lớn dữ liệu là hàng đã ngưng bán.


• Trạng thái xóa

- Biểu đồ cho thấy hầu hết sản phẩm đều có `is_deleted = False` (~26.000 sản phẩm chưa bị xóa).
- Số lượng sản phẩm đã xóa (`True`) rất nhỏ (không đáng kể).
- Insight: Trường `is_deleted` có ít ý nghĩa phân tách do dữ liệu quá mất cân bằng; nhưng vẫn hữu ích để lọc sản phẩm bị xóa ra khỏi tập huấn luyện hoặc báo cáo.

• Số lượng sản phẩm tạo mới theo tháng

- 2012–2016: gần như không đáng kể, số lượng mỗi tháng <50 sản phẩm.
- 2017–2019: bắt đầu tăng nhẹ, ổn định hơn.
- 2020–2021: tăng đột biến, đạt đỉnh vào 2021 (>1300 sản phẩm/tháng).
- 2022–2024: dao động thất thường, có xu hướng giảm dần nhưng vẫn cao hơn giai đoạn trước 2019.

- Đầu 2025: giảm mạnh so với 2021–2022.
- Insight: Có dấu hiệu bùng nổ sản phẩm trong giai đoạn Covid (2020–2021) – có thể do nhu cầu online tăng. Sau đó số lượng tạo mới giảm, có thể phản ánh xu hướng thị trường bão hòa hoặc thay đổi chiến lược kinh doanh.



2.1.2. Dữ liệu users

Biểu đồ 1: Phân tích nhân khẩu học

- Tỷ lệ giới tính

- Nữ: chiếm đa số (~74,9%).
- Nam: chiếm ~25,1%.
- Khác: gần như không đáng kể (0,1%).

Insight: Sản phẩm/dịch vụ thu hút nhiều người dùng nữ → có thể ảnh hưởng tới chiến lược marketing.

- Phân bố hạng thành viên

- Standard: chiếm tuyệt đối (~4 triệu người dùng).
- Gold & Diamond: số lượng rất thấp, gần như không tới 5–10% tổng số.

Insight: Tỷ lệ người dùng cao cấp rất nhỏ → cần xem xét ưu đãi/chính sách để tăng chuyển đổi từ Standard lên Gold/Diamond.

- Top 10 Tỉnh/Thành phố


- Hồ Chí Minh dẫn đầu vượt trội (~1,2 triệu người dùng).
 - Kế tiếp: Đồng Nai, Bình Dương, Hà Nội, Đà Nẵng... nhưng cách biệt khá xa.
- Insight: HCM là thị trường trọng điểm, nhóm kế tiếp tập trung quanh khu vực Đông Nam Bộ và đô thị lớn.

- Phân bố theo vùng miền

- Đông Nam Bộ đứng đầu (~1,7 triệu người dùng), sau đó là Đồng bằng sông Cửu Long và Duyên hải Nam Trung Bộ.

- Các khu vực miền Bắc và Tây Nguyên có ít người dùng hơn đáng kể.
Insight: Người dùng tập trung mạnh ở khu vực phía Nam → phù hợp cho định hướng quảng cáo và logistics.


Phân Tích Nhân Khẩu Học Người Dùng



Biểu đồ 2: Kênh & trạng thái

- **Nguồn đăng ký**
 - In-Store vượt trội với hơn 10^6 người dùng.
 - Các kênh khác: SPE, iOS, Android, Web dao động từ 10^4 – 10^5 .
 - Các kênh Call, Chat, Wholesale rất thấp.
 - Insight: Phần lớn người dùng đến từ cửa hàng offline (In-Store), ứng dụng di động và web chưa chiếm ưu thế → có thể tăng cường marketing online/app.
- **Trạng thái tài khoản**
 - 100% tài khoản đang hoạt động, chưa có tài khoản bị xóa.
 - Insight: Chất lượng dữ liệu tốt, không phải xử lý dữ liệu xóa.


Phân Tích Kênh Đăng Ký và Trạng Thái Tài Khoản



Biểu đồ 3: Tăng trưởng người dùng theo thời gian

- 2012–2017: tăng nhẹ, ổn định ở mức thấp (<10.000 người dùng/tháng).
- 2018–2022: tăng đều, nhưng vẫn ở mức trung bình.
- 2023 trở đi: tăng đột biến mạnh mẽ, nhiều tháng vượt 100.000 người dùng mới, đạt đỉnh vào cuối 2024–đầu 2025.

Insight: Tăng trưởng bùng nổ giai đoạn gần đây → cần nghiên cứu nguyên nhân (marketing, mở rộng thị trường, xu hướng TMĐT, ...) để tận dụng.



2.1.3. Dữ liệu purchases

Biểu đồ 1: Phân tích giá trị giao dịch

- **Phân bố giá trị giao dịch (Giá)**
 - Giá trị tập trung chủ yếu trong khoảng 8 – 13 đơn vị tiền tệ, tạo thành phân bố chuông (bell-shaped).
 - Có vài điểm giá cao hơn 15 nhưng hiếm → có thể là ngoại lệ/outlier.
 - Insight: Giá sản phẩm khá đồng đều, tập trung ở mức trung bình; không có nhiều sản phẩm giá quá thấp hoặc quá cao.
- **Phân bố số lượng sản phẩm/giao dịch**
 - Phần lớn giao dịch chỉ mua 1 sản phẩm, các giao dịch >3 sản phẩm rất ít.
 - Insight: Hành vi mua sắm chủ yếu là mua lẻ, không phải mua sỉ.
- **Phân bố mức giảm giá**
 - Mức giảm giá có xu hướng giống với giá sản phẩm, tập trung chủ yếu trong khoảng 8 – 13, cho thấy giảm giá tỷ lệ thuận với giá sản phẩm.
 - Insight: Chính sách khuyến mãi áp dụng đều theo giá trị sản phẩm, không quá phân tán.



Biểu đồ 2: Phân tích bối cảnh giao dịch

- **Tần suất các loại sự kiện**
 - 100% sự kiện ghi nhận là “Purchase” → dữ liệu tập trung hoàn toàn vào giao dịch mua bán.
 - Insight: Dữ liệu sự kiện sạch, không cần phân loại thêm.
- **Kênh thực hiện giao dịch**
 - In-Store (Cửa hàng) chiếm tuyệt đối ($\sim 3 \times 10^7$ giao dịch).
 - Các kênh iOS, SPE, Android, Web... chỉ chiếm tỷ lệ rất nhỏ.
 - Insight: Người dùng vẫn chuộng mua hàng trực tiếp tại cửa hàng → kênh online chưa phát triển mạnh.


• Phương thức thanh toán

- Tiền mặt chiếm ưu thế vượt trội ($>2 \times 10^7$ giao dịch).
- Các phương thức không tiền mặt như VietQR, cà thẻ, ví điện tử (VNPay, Momo, ShopeePay) chỉ chiếm tỷ lệ nhỏ.
- Insight: Xu hướng thanh toán vẫn thiên về tiền mặt → có thể tăng cường khuyến khích thanh toán số để tối ưu vận hành và giảm chi phí.



Biểu đồ 3: Xu hướng giao dịch theo thời gian


- Số lượng giao dịch mỗi ngày dao động 80.000 – 120.000 sự kiện/ngày.
- Xuất hiện các đỉnh tăng đột biến vào khoảng tháng 2, tháng 6 và tháng 12/2024 (vượt 180.000 – 200.000 sự kiện/ngày).
- Insight: Các đỉnh giao dịch có thể trùng với các chiến dịch khuyến mãi, mùa lễ hội (Tết, mid-year sale, end-year sale).
- Ngoài các đỉnh này, số lượng sự kiện giữ mức ổn định quanh 100.000/ngày → cho thấy tệp khách hàng ổn định quanh năm.



2.2. Phân tích Đa biến


Biểu đồ 1: Phân tích giá trị giao dịch

- Ba biểu đồ histogram thể hiện phân bố giá trị giao dịch, số lượng sản phẩm/giao dịch, và mức giảm giá.
 - Phân bố giá có dạng chuông (bell-shaped), tập trung trong khoảng 8–13 đơn vị tiền tệ. Phần lớn giao dịch diễn ra ở mức giá trung bình, ổn định.
 - Số lượng sản phẩm/giao dịch chủ yếu là 1-2 sản phẩm, hành vi mua lẻ chiếm ưu thế.
 - Mức giảm giá cũng tập trung quanh 8–13, cho thấy chính sách khuyến mãi mãi tương đối đồng đều giữa các sản phẩm.




Biểu đồ 2: Phân tích giá trị Khách hàng

- Hai biểu đồ histogram thể hiện tổng doanh thu trên mỗi khách hàng và số lần mua hàng trên mỗi khách hàng.
 - Doanh thu trung bình/khách hàng phân bố lệch phải, phần lớn tập trung ở mức vừa phải, một số khách hàng chi tiêu cao nổi bật.
 - Số lần mua hàng giảm dần theo quy luật Pareto: đa số khách chỉ mua 1–2 lần, rất ít khách hàng có tần suất cao.



Biểu đồ 3: Phân tích hiệu suất danh mục


- Biểu đồ bubble chart biểu diễn mối quan hệ giữa tổng số sản phẩm bán ra và tổng doanh thu theo từng danh mục cấp 1.
 - Nhóm Babycare có doanh thu và số lượng bán cao nhất, thể hiện vai trò chủ lực.
 - Các nhóm như Thời trang, Đồ chơi & Sách cũng tạo doanh thu đáng kể nhưng thấp hơn.
 - Một số danh mục nhỏ tạo ít doanh thu dù số lượng bán khá lớn. Suy ra, biên lợi nhuận thấp.



Biểu đồ 4: Phân tích giỏ hàng

- Heatmap biểu diễn tần suất các danh mục được mua cùng nhau.


- Các ô có giá trị cao nằm trên đường chéo và quanh nhóm Babycare – Thời trang – Phụ kiện, cho thấy người mua thường kết hợp các sản phẩm cho trẻ nhỏ.
- Các nhóm như Tã, Vệ sinh, Thực phẩm cho bé cũng có xu hướng đồng mua cao.



Biểu đồ 5: phân tích thời gian mua sắm


- Heatmap thể hiện mật độ giao dịch theo giờ và ngày trong tuần.
 - Mật độ cao nhất rơi vào buổi sáng (9–11 giờ) và chiều tối (17–20 giờ).

- Cuối tuần (đặc biệt thứ Bảy, Chủ nhật) có lượng giao dịch tăng mạnh so với các ngày thường.




Biểu đồ 6: Mối quan hệ giữa giá và lợi nhuận

- Scatterplot biểu diễn tương quan giữa giá (price) và lợi nhuận (gp) của sản phẩm.
 - Xu hướng tuyến tính dương rõ rệt khiến giá cao đi kèm lợi nhuận cao.
 - Tuy nhiên độ phân tán lớn ở nhóm giá trung bình, suy ra lợi nhuận còn phụ thuộc yếu tố khác (chi phí sản xuất, thương hiệu,...).




Biểu đồ 7: Giá trung bình theo danh mục

- Boxplot biểu diễn phân bố giá (price) theo từng category_11.
 - Hầu hết danh mục có giá thấp và ổn định; Babycare và Thời trang có phạm vi giá rộng, xuất hiện nhiều outlier → đa dạng sản phẩm.
 - Các danh mục khác như TPCN, Sữa, Phụ kiện có giá khá đồng nhất.
 - Chênh lệch giá giữa các nhóm hàng cao; nhóm Babycare cần được phân tách sâu hơn khi dự đoán giá hoặc phân khúc thị trường.




Biểu đồ 8: số lượng sản phẩm mua theo membership

- Bar chart thể hiện tổng số sản phẩm được mua bởi từng hạng thành viên.
 - Standard chiếm phần lớn giao dịch, tiếp đến Gold, và Diamond thấp nhất.
 - Mức tiêu thụ giảm dần theo cấp thành viên, phản ánh cơ cấu khách hàng chủ yếu vẫn là người mới hoặc không trung thành.




Biểu đồ 9: Doanh thu theo thời gian

- Line chart biểu diễn tổng doanh thu theo ngày từ 2012–2025.
 - Doanh thu tăng đều đến giai đoạn 2021–2023, đạt đỉnh vào cuối 2023 – đầu 2024, sau đó giảm dần.
 - Giai đoạn tăng mạnh trùng với thời kỳ bùng nổ thương mại điện tử hậu Covid.



Biểu đồ 10: Phân bố người dùng theo vùng

- Bar chart thể hiện số lượng người dùng ở từng vùng.
 - Đông Nam Bộ dẫn đầu vượt trội, kế đến Đồng bằng sông Cửu Long và Duyên hải Nam Trung Bộ.
 - Các vùng miền Bắc và Tây Nguyên có lượng người dùng thấp hơn đáng kể.



3. Nhận định và đề xuất tiền xử lý dữ liệu

3.1. Tổng hợp các vấn đề từ bộ dữ liệu

3.1.1. Dữ liệu Sản phẩm (Items)

- Nhiều trường thông tin chi tiết như color, size, material, origin, weight có giá trị thiếu hoặc “Không xác định”.
- Biến sale_status mất cân bằng mạnh, phần lớn sản phẩm ở trạng thái “còn bán”.
- Các biến số như price và gp xuất hiện nhiều giá trị ngoại lệ (outlier), đặc biệt ở nhóm giá cao.
- Một số danh mục (category_11, category_12) có số lượng sản phẩm quá chênh lệch, gây mất cân đối trong phân tích.

3.1.2. Dữ liệu Người dùng (Users)

- Các trường gender và membership có phân bố không đồng đều, nhóm “Standard” chiếm đa số.
- Một số bản ghi có trùng lặp customer_id hoặc thiếu thông tin cá nhân (region, province).
- Các trường install_app và install_date có định dạng không thống nhất giữa các bản ghi.

3.1.3. Dữ liệu Giao dịch (Purchases)

- Có một số giá trị price hoặc discount bằng 0 hoặc âm, cho thấy lỗi nhập liệu.
- Trường thời gian (timestamp, created_date) chưa được chuyển sang dạng datetime, gây khó khăn cho phân tích chuỗi thời gian.
- Các trường channel và payment chứa một số nhóm rất nhỏ, ảnh hưởng đến tính đại diện.
- Biến quantity có phân bố lệch phải mạnh, phần lớn bằng 1.

3.2. Đề Xuất

Những trường thông tin nào không có nhiều thông tin → nên loại bỏ

- Trong bảng item_chunk, các trường như: **image_url, description, description_new, material, size, weight, color** có tỷ lệ giá trị trống (NULL) rất cao, và phần lớn là “Không xác định”.
 - Điều này đã được phát hiện qua biểu đồ kiểm tra giá trị thiếu (Task 1 – Dữ liệu Items), nơi các cột này có số lượng NaN vượt 70%.
 - Vì đây là các cột mang tính mô tả chi tiết, ít ảnh hưởng đến phân tích giá và hành vi mua, nhóm quyết định loại bỏ để giảm độ nhiễu và dung lượng dữ liệu.
- Ngoài ra, trong bảng user_chunk, trường **sync_error_message** và **is_deleted** chỉ chứa giá trị 0 hoặc NULL, không mang ý nghĩa phân tích, nên cũng có thể bỏ qua.

Những trường thông tin nào cần xử lý giá trị thiếu (NULL)

- Trong bảng user_chunk, các trường **province, region, district, gender, và membership** có một phần dữ liệu bị thiếu.
 - Điều này được thấy rõ trong biểu đồ phân bố khu vực và giới tính (Task 1 – Dữ liệu Users), khi tổng số lượng người dùng theo vùng thấp hơn tổng số bản ghi.
 - Các giá trị thiếu này ảnh hưởng đến việc phân tích địa lý và hành vi khách hàng, nên cần điền bằng giá trị phổ biến nhất hoặc “Unknown”.
- Trong bảng item_chunk, các trường **brand, origin và manufacturer** có một phần bị thiếu, điều này có thể ảnh hưởng đến biểu đồ phân tích thương hiệu (Task 1 – Dữ liệu Items).

- Cần thay thế bằng “Không xác định” hoặc “Other” để giữ lại dữ liệu thay vì loại bỏ dòng.
- Trong bảng `purchase_history`, các trường **payment** và **channel** đôi khi bị trống, nhưng chúng là thông tin quan trọng trong biểu đồ “Kênh mua hàng” và “Phương thức thanh toán” (Task 1 – Dữ liệu Purchase), do đó cần điền giá trị mặc định “Unknown” để đảm bảo tính thống nhất.

Những trường thông tin nào cần xử lý ngoại lệ (Outlier)

- Trong bảng `item_chunk`, các trường **price** và **gp** có nhiều giá trị bất thường.
 - Qua biểu đồ histogram và boxplot trong Task 1 – Dữ liệu Items, ta thấy phân bố giá lệch phải mạnh, một số giá trị cao gấp nhiều lần trung bình.
 - Các ngoại lệ này có thể làm sai lệch trung bình giá và mô hình dự đoán doanh thu, vì vậy cần loại bỏ hoặc cắt theo ngưỡng IQR (Interquartile Range).
- Trong bảng `purchase_history`, biến **discount** và **quantity** cũng xuất hiện các giá trị âm hoặc cực lớn, được phát hiện trong biểu đồ “Phân tích giá trị giao dịch” (Task 2 – Biểu đồ 1).
 - Cần lọc bỏ giá trị âm, và giới hạn discount tối đa (ví dụ $\leq 100\%$) để tránh lỗi nhập liệu.

Những trường thông tin nào cần xử lý phân bố không đều

- Biểu đồ “Giá trung bình theo danh mục” và “Phân tích hiệu suất danh mục” (Task 2 – Biểu đồ 3 & 7) cho thấy **category_l1** và **category_l2** có **phân bố rất mất cân bằng**, nhóm **Babycare** và **Fashion** chiếm tỷ trọng lớn.
 - Điều này khiến các mô hình học máy có thể thiên lệch về nhóm phổ biến, cần thực hiện gộp nhóm nhỏ thành “Other” hoặc lấy mẫu cân bằng (sampling).
- Trong bảng `user_chunk`, biến **membership** và **region** cũng mất cân bằng rõ rệt theo biểu đồ “Số lượng sản phẩm theo hạng thành viên” (Task 2 – Biểu đồ 8) và “Phân bố người dùng theo vùng” (Task 2 – Biểu đồ 10).
 - Đề xuất **cân bằng lại phân bố dữ liệu** bằng **trọng số** hoặc **sampling có phân tầng**, đặc biệt khi huấn luyện mô hình dự đoán hành vi khách hàng.